

¿Aprendizaje o Memorización?




0 50 100 150




La Pregunta Central:
¿Cómo sabemos si un modelo aprendió algo útil y no solo memorizó los datos?

La Realidad: Un modelo útil solo se demuestra cuando supera un baseline en datos no vistos y se evalúa con métricas estrictamente alineadas al costo real del error.

Objetivos del Recorrido: Reconocer la anatomía de los datos, trazar fronteras de decisión, aislar el conocimiento e interpretar el costo de equivocarnos.




La Anatomía de un Dataset



El modelo solo ve representaciones numéricas; el significado humano depende del contrato de los datos.

Muestra (Fila)	Feature (Columna / Matriz X)	Label (Vector y)
El caso individual indivisible (Ej. Un paciente, una parcela, una imagen).	La información de entrada. Pueden ser numéricas, categóricas, binarias, secuenciales (texto/audio) o espaciales (píxeles/bandas).	La respuesta conocida o resultado esperado que queremos predecir (Ej. Nivel de riesgo, especie, clase).

El Mapa del Aprendizaje Automático




Nota: Feature Engineering


El arte de transformar datos crudos en variables numéricas útiles que el algoritmo pueda aprovechar (ej. convertir dos bandas espectrales a un índice). Toda transformación debe documentarse y repetirse idéntica en producción.

El Ciclo de Vida: Aislamiento Estratégico


Evaluar con los mismos casos usados para aprender produce una ilusión de éxito.




El Espejismo del Entrenamiento



Underfitting: Train bajo / Validation bajo. El modelo no captura el patrón.



Ajuste Razonable: Train alto / Validation parecido. El patrón se sostiene fuera del entrenamiento (Generalización).




Overfitting: Train muy alto / Validation claramente menor. El modelo memorizó detalles irrelevantes.

El Generalization Gap: La diferencia crítica de rendimiento entre Train y Validation. Su interpretación siempre depende de la naturaleza del problema real.

El Enemigo Invisible: Data Leakage

PROBLEM (FUGA)




Leakage ocurre cuando el **entrenamiento recibe información futura que no debería tener**. Ej: Normalizar usando el promedio de todo el dataset completo antes de separar.

Componentes que aprenden solo de Train:

- **Scalers:** Aprenden promedio y dispersión para cambiar escala.
- **Imputadores:** Aprenden el valor para reemplazar faltantes.

SOLUTION (EL ESCUDO)



El Escudo (Pipelines): Encadenan transformaciones y modelo en un orden estricto. Garantizan que las estadísticas se calculen exclusivamente sobre Train, protegiendo Validation y Test de la contaminación.

Clasificación: Trazando Fronteras

feature 2
^
| 0 0 región predicha como clase 0
| 0 0
| frontera
| 1 1
| 1 1 región predicha como clase 1
+-----> feature 1



Clasificar es elegir una categoría entre alternativas conocidas. El algoritmo aprende una frontera de decisión: una separación literal entre regiones del espacio de datos.



Loss: La señal matemática interna usada para ajustar el modelo.




Métrica: El número legible usado por humanos para interpretar el resultado.



Costo Real: La consecuencia humana, clínica o financiera del error en la realidad.

Comparativa de Algoritmos (Clasificación)


K-Nearest Neighbors



Intuición: Votan los k vecinos más cercanos (no hay fórmula global).

Riesgo Inicial: Muy sensible a la escala de los datos y al ruido.


Árbol de Decisión



Intuición: Encadena preguntas sucesivas con umbrales absolutos.

Riesgo Inicial: Una profundidad excesiva memoriza Train creando una frontera híper-flexible.

Regresión Logística




Intuición: Separación lineal probabilística (usa un umbral, ej. 0.5).

Riesgo Inicial: Puede no capturar fronteras curvas complejas. Usa regularización para evitar parámetros extremos.

La Matriz de Confusión y sus Consecuencias

Importante: "Positivo" no significa bueno; es la clase de interés específico que buscamos detectar.



Lentes de Evaluación (Métricas de Clasificación)




Regresión: Prediciendo el Continuo

En lugar de elegir categorías, estimamos un valor numérico continuo.


Ejemplo:

Horas/día -> Demanda (37.4 consultas).
Bandas espectrales -> Cobertura (62.1%).

La Realidad del Error: La estimación casi nunca coincide exactamente con la realidad. En regresión no preguntamos "¿acertó?", sino "¿qué tan lejos quedó?".




Midiendo la Distancia (Métricas de Regresión)



MAE

(Distancia Absoluta Promedio)


Se lee en las mismas unidades que la salida. Representa el error típico y esperado.



RMSE

(Raíz del Error Cuadrático Medio)

Se lee en las mismas unidades, pero penaliza de manera severa y enfatiza los errores grandes o extremos.



R²

(Varianza Explicada)

Un puntaje relativo. 1 es un modelo perfecto. 0 equivale a predecir siempre el promedio. Un puntaje negativo significa que es literalmente peor que adivinar la media.

El Costo del Error Dicta la Métrica

La métrica nunca se elige por popularidad, sino por el daño que el error produce en la realidad clínica o del negocio.




	Problema	Justificación del Costo	Métrica Recomendada
1	Queremos reducir pacientes omitidos	El falso negativo es letal	Recall
2	Evitar fatiga por alarmas	Las alertas deben tener confianza absoluta	Precision
3	Estimar cantidad de insumos	Necesitamos el error en unidades reales	MAE
4	Comparar segmentaciones médicas	Medir superposición visual de regiones	IoU (Intersection over Union)




La Regla de Oro del Baseline

El Baseline: Una referencia extremadamente simple (y tonta) que no intenta aprender relaciones complejas.



Modelo Complejo
(Esfuerzo Excesivo)

```
regresores = {  
    "Baseline media": DummyRegressor(strategy="mean"),  
    "Regresión lineal": LinearRegression(),  
}  
for nombre, modelo in regresores.items():  
    modelo.fit(X_reg_train, y_reg_train)
```



Baseline
(Regla Simple)

- **Ejemplo en Regresión:** Predecir SIEMPRE el promedio del dataset de Train.
- **Ejemplo en Clasificación:** Predecir SIEMPRE la clase mayoritaria.

LA REGLA: Un modelo de Machine Learning complejo no aporta ningún valor si no puede superar consistentemente al baseline en datos no vistos. Superarlo es el requisito mínimo de existencia.

Síntesis y Próximos Pasos

El Veredicto Final

 **Train** aprende. **Validation** compara. **Test** examina. **Nunca mezclar los flujos.**

 **La métrica es humana:** no se escoge por matemática, sino según el **costo del error real.**

 **Un modelo sin un baseline rigurosamente definido** es simplemente **una ilusión.**

Próxima Estación (Clase 3)

 **Representación Numérica:** ¿Cómo convertimos el caos del mundo real (texto libre, audio, imágenes y datos geospaciales) en los **números exactos que estos algoritmos necesitan para operar?**

 **Conexión con Tracks:** Aplicaremos este rigor evaluativo directamente a la clasificación clínica (Salud) y la detección de píxeles u objetos (Imagen).



**El Puente hacia la Representación Numérica
y Aplicaciones Especializadas**