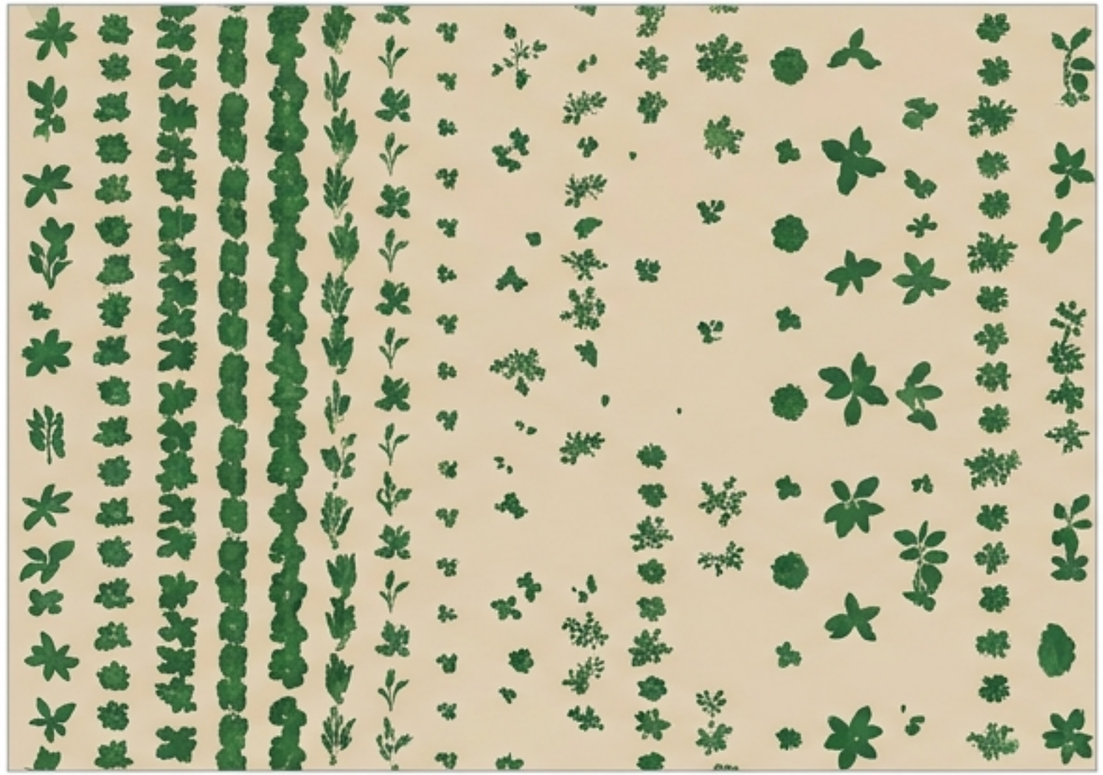
Pintar el lote píxel por píxel.

Fundamentos de segmentación de imágenes en agricultura de precisión.

Gemini Notebook

El límite analítico de la señal de vegetación.



Los índices tradicionales nos indican con precisión dónde hay actividad fotosintética. La señal confirma: «**aquí hay algo** parecido a vegetación».



Sin embargo, esta señal es insuficiente para decisiones complejas. No nos dice qué planta es, ni **marca las fronteras físicas donde termina un individuo y empieza el siguiente.** El siguiente paso analítico exige **etiquetar el terreno.**

Gemini Notebook

La respuesta algorítmica depende de la pregunta agronómica.



Clasificación
¿Hay maleza en esta foto? Entrega una etiqueta global para toda la imagen.



Detección
¿Dónde está cada planta? Entrega un recuadro delimitador espacial por individuo.

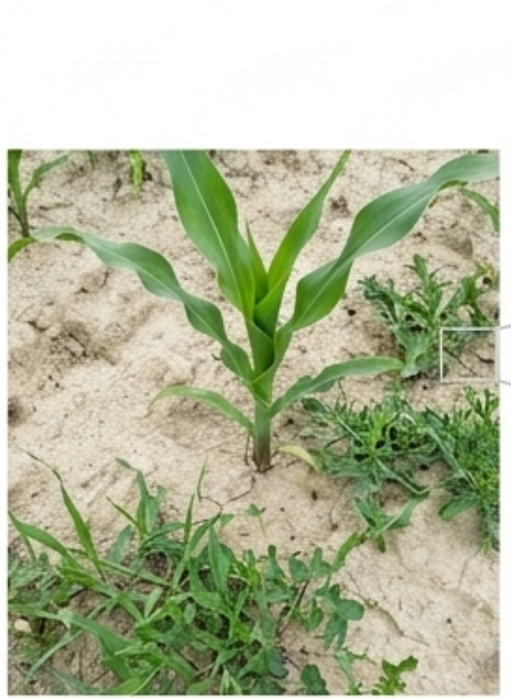


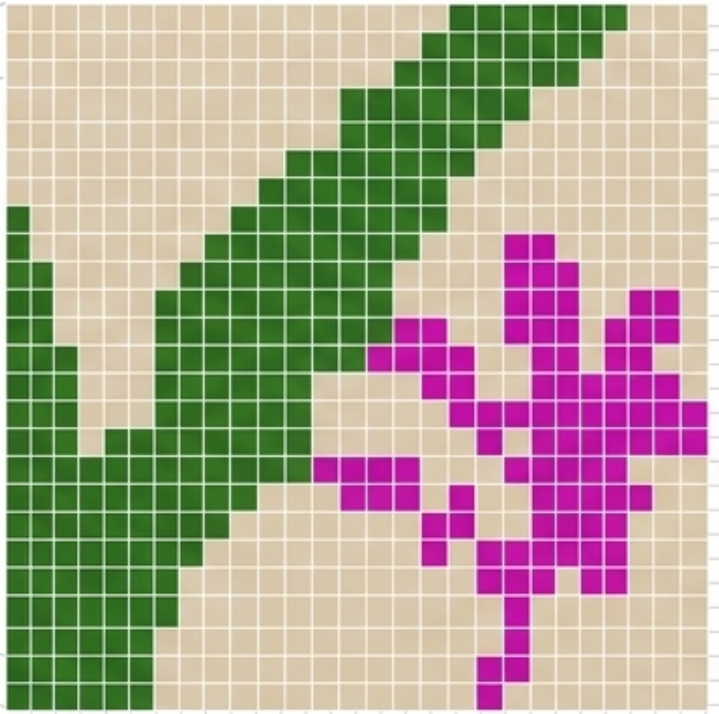
Segmentación
¿Qué píxeles exactos son maleza? Entrega un mapa detallado y clasificado.

Gemini Notebook

Segmentar es la tarea de clasificar la unidad mínima.

Segmentar implica producir un mapa de alta resolución donde cada píxel individual recibe una etiqueta categórica (suelo, cultivo o maleza). El resultado de este proceso no es una foto mejorada, sino una nueva capa de datos llamada máscara.

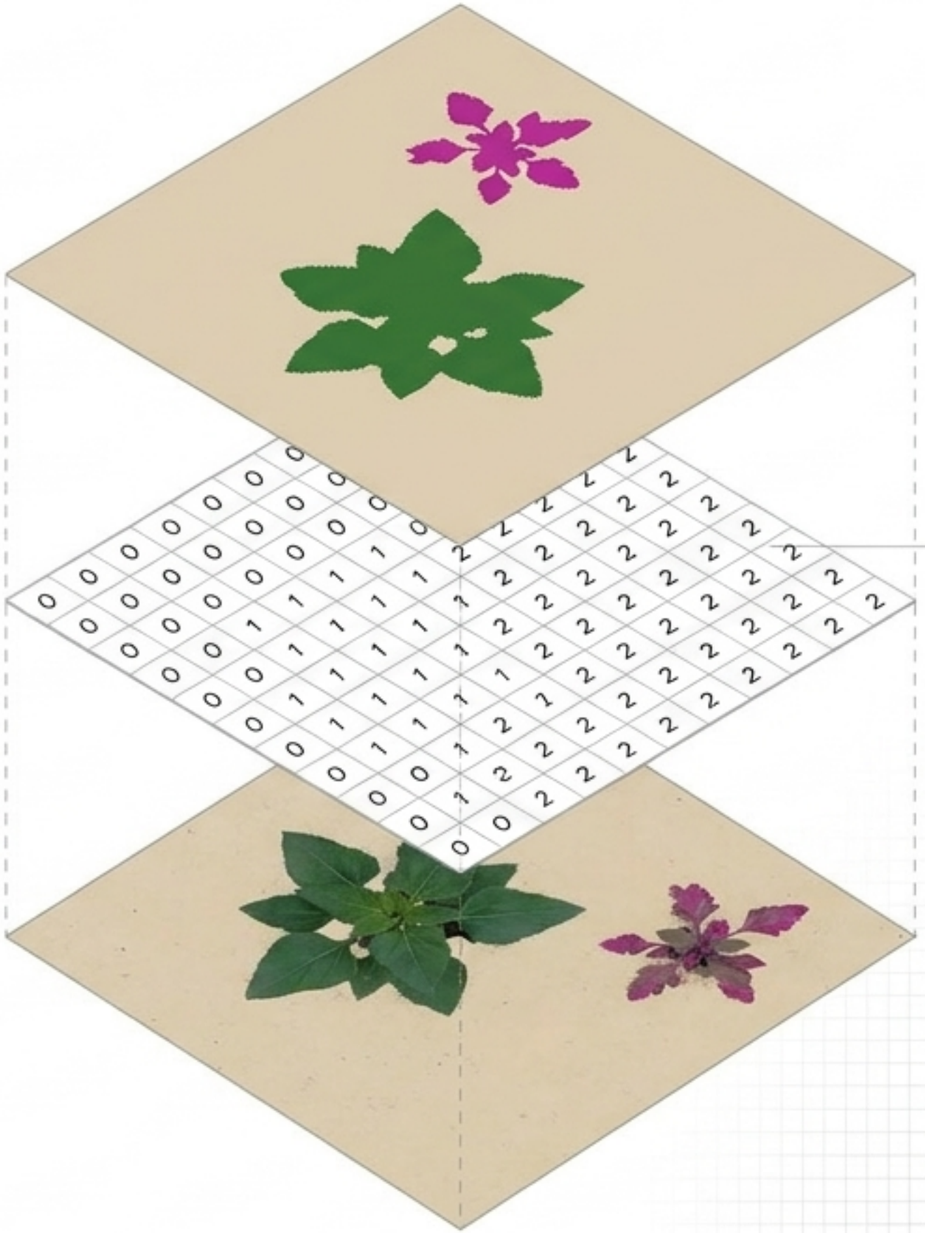




Gemini Notebook

La anatomía de una máscara de segmentación.

Una máscara es una imagen de respuestas que posee exactamente las mismas dimensiones que la foto original.



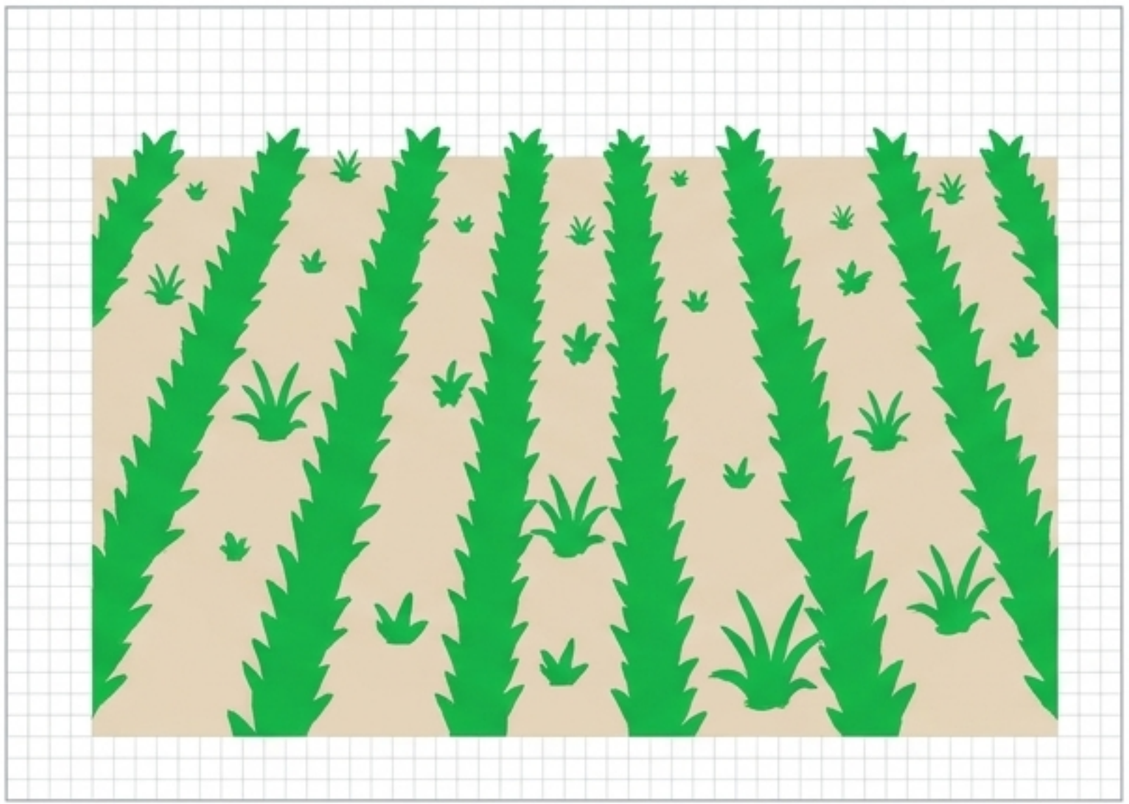
Donde la fotografía almacena valores de luz (RGB), la máscara almacena etiquetas funcionales:
0 = Suelo, 1 = Cultivo, 2 = Maleza.

Gemini Notebook

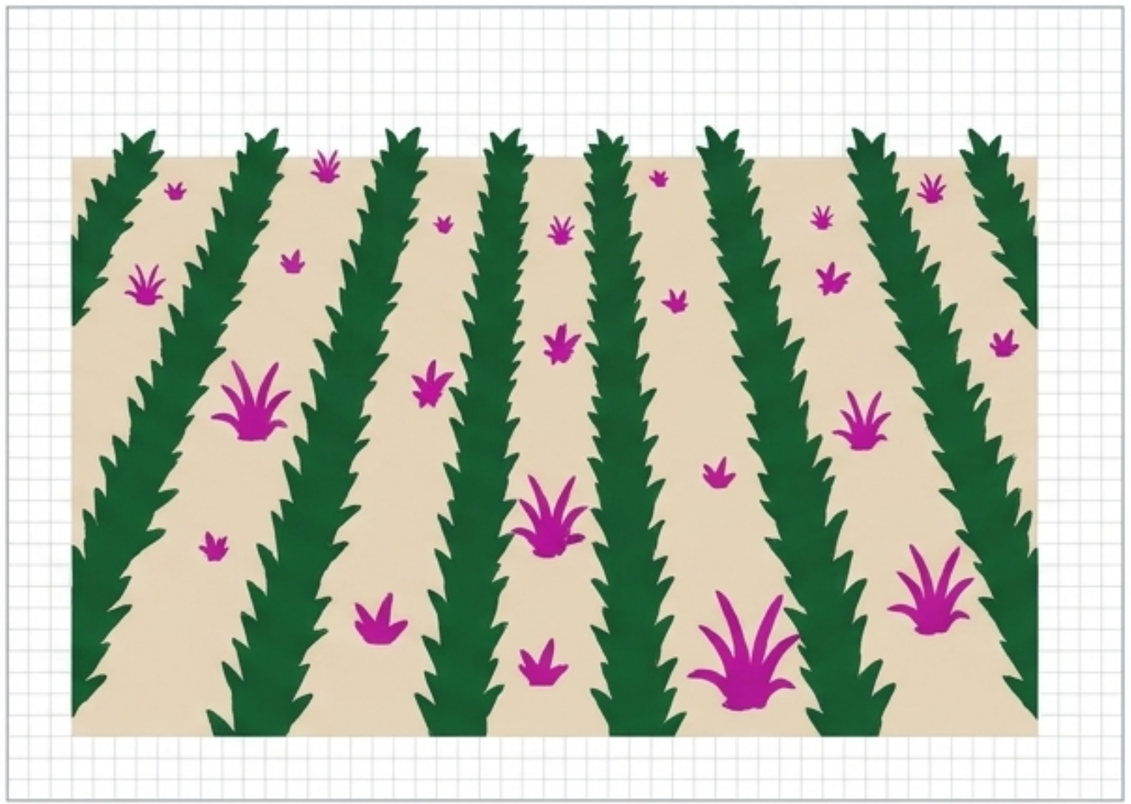
El color por sí solo es ciego al contexto agronómico.

Tanto el cultivo como la maleza son vegetación. Una regla automática de agrupación por color (como K-Means) promediará los tonos y mezclará ambos elementos sin distinción. La máquina no puede identificar malezas analizando únicamente el espectro de luz; necesita comprender el contexto.

Regla automática (K-Means)



Etiqueta semántica humana



Gemini Notebook

La definición funcional de la maleza requiere conocimiento humano.

«Maleza» no es una especie botánica fija; es cualquier planta que sobra en un lote específico. La misma especie puede ser maleza en un campo y cultivo en otro.



Etiquetar genera dudas naturales. En el borde de una hoja, dos expertos pueden discrepar sobre a qué píxel pertenece. El modelo aprende de la realidad, incluyendo estos desacuerdos naturales.

Gemini Notebook

Dos caminos métricos para pintar un mapa.

Segmentación Semántica

Pinta todos los píxeles de una misma categoría del mismo color.

Responde a la pregunta:
¿Qué píxeles son maleza?
No distingue dónde termina una planta y comienza otra.

Segmentación por Instancia

Pinta cada planta con un identificador (color o número) único.

Responde a la pregunta:
¿Cuántas plantas hay y dónde está cada una exactamente?

Gemini Notebook

Cobertura: 8%



Enfoque Semántico: Prioridad en la superficie.

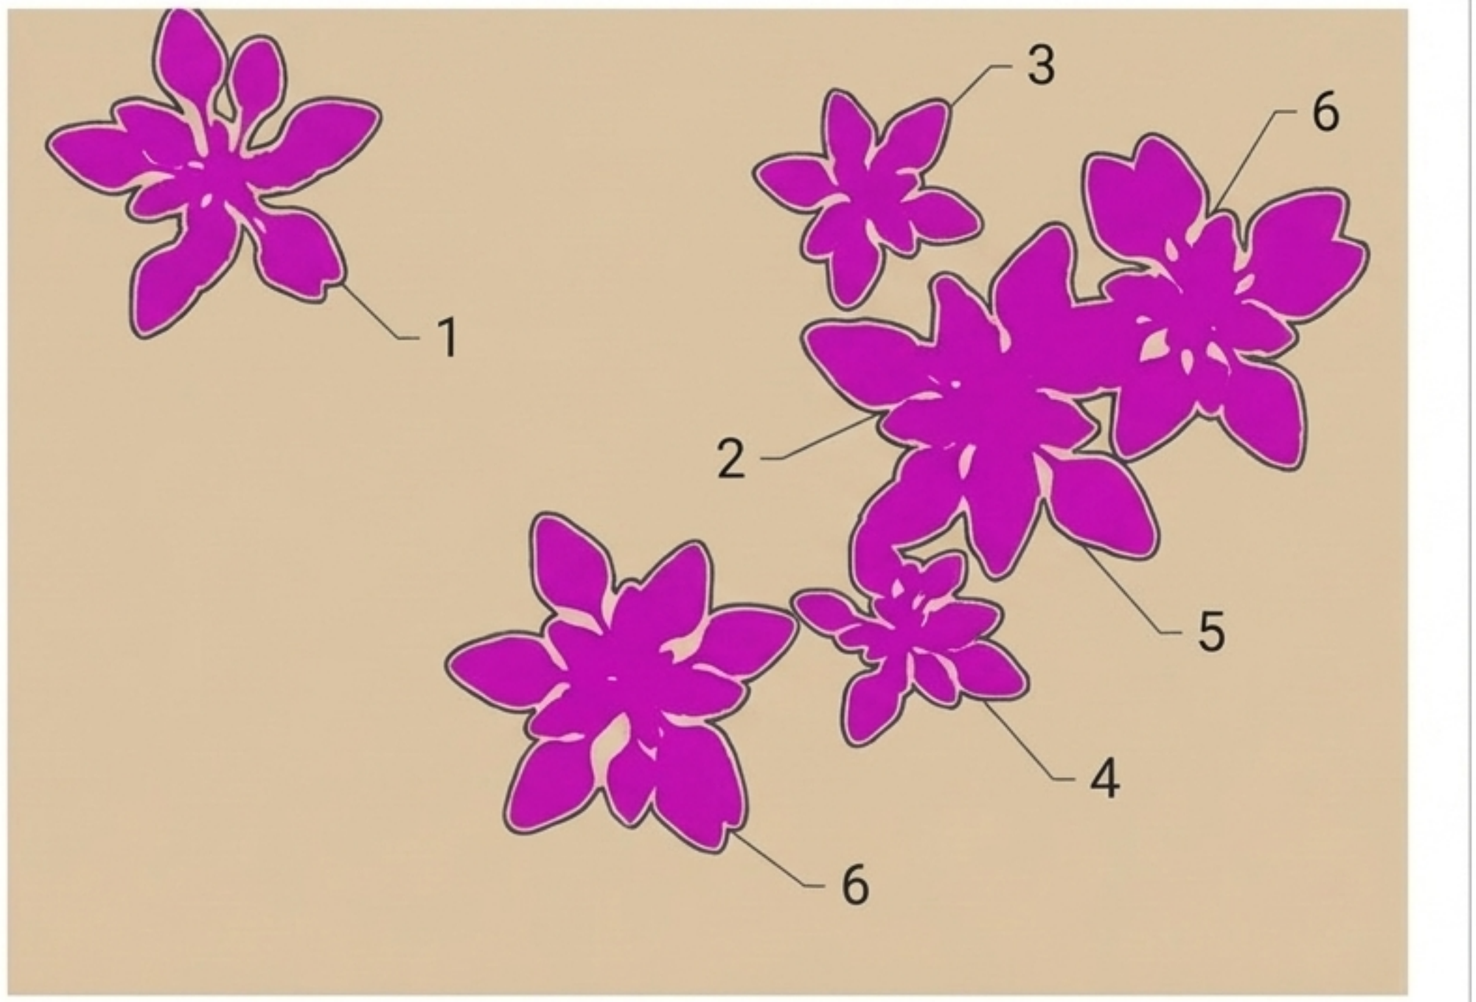
Al unificar el color de todos los elementos de una categoría, obtenemos la métrica de cobertura total.

Sabemos con precisión cuánta superficie física está ocupada (ej. 8% del lote afectado), pero es imposible determinar algorítmicamente cuántos individuos componen esa masa sin contarlos a ojo.

Ideal para mapas de calor.

Gemini Notebook

Conteo: 6 individuos



Enfoque por Instancia: Prioridad en la individualización.

Al asignar un identificador único a cada forma, el algoritmo logra separar y contar objetos. Permite el conteo automatizado del stand de plantas y la ubicación exacta en el espacio. Ideal para planificar pasadas mecánicas o químicas selectivas (spot spraying) planta por planta.

Gemini Notebook

Matriz de decisión agronómica.

Objetivo en el lote	Enfoque algorítmico	Ejemplo de resultado
Medir la superficie total con maleza	Semántica	«El 8% del sector está cubierto»
Contar plantas individuales en un área	Por Instancia	«Hay 6 plantas en este cuadrante»
Planificar acción selectiva (planta a planta)	Por Instancia	Coordenadas exactas por cada individuo

Gemini Notebook

La maquinaria: Cómo aprenden los modelos.

Existen arquitecturas estándar en la industria para automatizar la segmentación. Su matemática interna es compleja, pero su lógica de negocio es simple.

Ambos modelos requieren fotografías con máscaras previamente hechas por personas para poder entrenar. Sin datos supervisados por expertos, no hay aprendizaje ni segmentación inteligente.

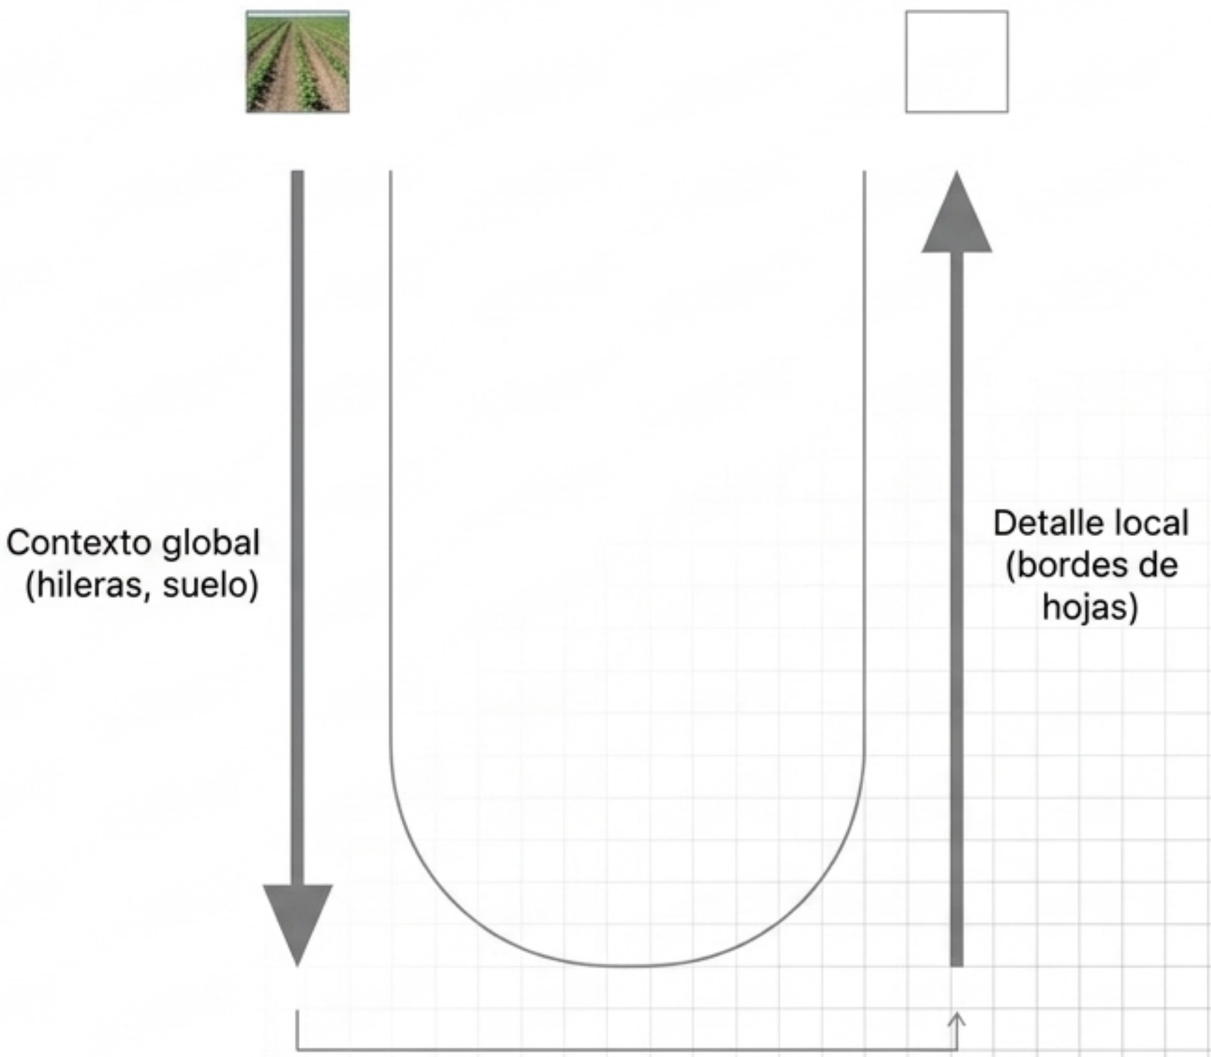


Gemini Notebook

U-Net: El estándar de segmentación semántica.

Entra una foto, sale una máscara categórica del mismo tamaño.

Mecanismo
Su arquitectura comprime primero la imagen para entender la «idea general» del escenario (mirar de lejos) y luego la expande para recuperar la resolución y definir los bordes exactos (mirar de cerca).
Ideal para generar mapas de cobertura de forma masiva.



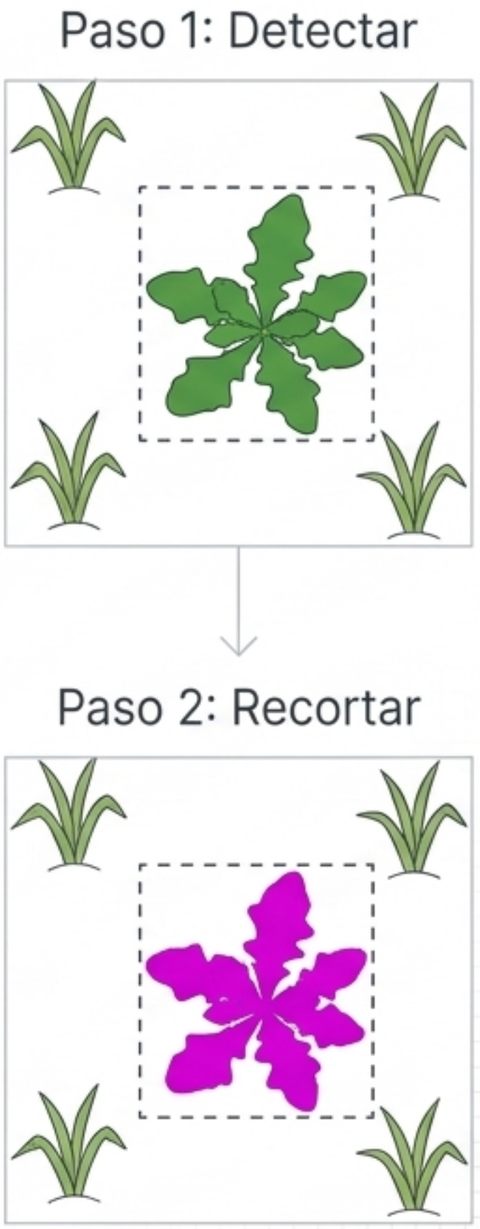
Gemini Notebook

Mask R-CNN: El estándar de segmentación por instancia.

Entra una foto, salen recuadros y siluetas por cada planta detectada.

Mecanismo

Primero actúa como un detector, encerrando plantas candidatas en recuadros (Bounding boxes).
Segundo, actúa como un bisturí, recortando y pintando la silueta exacta únicamente dentro de ese recuadro.



Gemini Notebook

Síntesis del análisis espacial.

1

La granularidad es clave. Segmentar trasciende la detección; exige clasificar la imagen píxel por píxel para obtener métricas de forma y área.

2

El contexto supera al color. Las reglas automáticas de agrupación óptica mezclan vegetación. La máscara debe reflejar la definición humana de qué sobra en el lote.

3

Elección dirigida por el problema. Se utiliza el enfoque Semántico (U-Net) para medir superficies, y el enfoque de Instancia (Mask R-CNN) para contar individuos.

4

Conexión con el terreno real. Para escalar esta tecnología, la fotografía RGB de alta nitidez no basta; requiere recortes alineados y máscaras de referencia verificadas.

Gemini Notebook